

Raport z projektu Advanced Data Mining

Temat: Nienadzorowane wykrywanie anomalii w trasach taksówek: porównanie reprezentacji samonadzorowanych (TS2Vec) z klasyczną inżynierią cech (Baseline).

Autorzy: Hubert Stolarz, Karol Kulig

1. Wstęp i definicja problemu

Głównym celem naszego projektu było stworzenie systemu zdolnego do automatycznego wykrywania anomalii w danych GPS pochodzących z przejazdów taksówek. W rzeczywistym ruchu miejskim anomalie mogą przyjmować różną postać: od celowych oszustw kierowców (np. drastyczne nadkładanie drogi), przez błędy techniczne urządzeń pomiarowych (np. nierealistyczne teleportacje), aż po rzadkie, nietypowe wzorce poruszania się.

Fundamentalnym problemem w tym zadaniu był całkowity brak etykiet. Zbiór danych nie zawierał informacji o tym, które przejazdy są poprawne, a które stanowią anomalię. Z tego powodu nie mogliśmy zastosować standardowych algorytmów klasyfikacji, a nasz projekt musiał opierać się na uczeniu nienadzorowanym oraz zaprojektowaniu autorskiej metody weryfikacji wyników.

2. Zbiór danych i przetwarzanie wstępne

Do eksperymentów wykorzystaliśmy publicznie dostępny zbiór danych "Porto Taxi" (pochodzący z wyzwania ECML-PKDD 2015). W oryginalnej formie zbiór ten zawierał około 1.7 miliona przejazdów zrealizowanych w ciągu jednego roku. Każda trasa zapisana była jako ciąg współrzędnych z próbkowaniem co 15 sekund.

Ze względu na ograniczenia obliczeniowe oraz w celu odsumienia danych, przeprowadziliśmy proces czyszczenia. Odrzuciliśmy trasy oznaczone flagą błędnych danych (MISSING_DATA) oraz przejazdy skrajnie krótkie lub nienaturalnie długie (np. sytuacje, gdy taksometr pozostał włączony na postoju). Następnie zastosowaliśmy próbkowanie systematyczne, wybierając co 30. rekord. Dzięki temu uzyskaliśmy reprezentatywną, czystą próbę 54 573 przejazdów, która posłużyła do dalszych analiz, zachowując proporcje ruchu miejskiego z całego roku.

Link do datasetu: <https://www.kaggle.com/c/pkdd-15-predict-taxi-service-trajectory-i/data>

3. Proponowane metody

Aby ocenić skuteczność różnych podejść do reprezentacji danych, zestawiliśmy ze sobą dwie przeciwstawne metody. Obie reprezentacje zostały ostatecznie ocenione przez ten sam algorytm wykrywania anomalii – Isolation Forest.

Podejście Baseline (Klasyczna inżynieria cech)

W tym wariantcie każdą trasę zredukowaliśmy do 8 ręcznie zaprojektowanych, zrozumiałych statystyk opisowych. Były to m.in.: całkowita długość trasy, liczba punktów pomiarowych,

odległość w linii prostej od startu do celu, średnia i maksymalna prędkość, współczynnik objazdu (detour ratio) oraz przekątna ramki otaczającej (bounding box diagonal).

Podejście TS2Vec (Głębokie uczenie reprezentacji)

Zamiast wyliczać gotowe cechy, potraktowaliśmy trasę jako wielowymiarowy szereg czasowy. Aby uniezależnić model od konkretnych lokalizacji na mapie, surowe współrzędne zamieniliśmy na 3-kanalowe wejście: przyrost długości geograficznej, przyrost szerokości oraz prędkość pojazdu. Ponieważ trasy różniły się długością, wyrównaliśmy je do 200 kroków czasowych, uzupełniając brakujące miejsca wartościami pustymi.

Wykorzystaliśmy nowoczesny, samonadzorowany model TS2Vec, który uczył się struktury ruchu miejskiego na losowej próbie 10 tysięcy tras. Na koniec działania sieci, w procesie uśredniania (mean-pooling), model kompresował każdą trasę do pojedynczego wektora składającego się z 320 liczb.

4. Metodologia ewaluacji

Z powodu braku oryginalnych etykiet, do oceny ilościowej modeli zastosowaliśmy technikę syntetycznego wstrzykiwania anomalii. Wybraliśmy losowe, poprawne trasy i programowo wprowadziliśmy w nich cztery rodzaje zniekształceń:

1. **Detour:** wklejenie w środek trasy sztucznej pętli o długości ok. 2 km.
2. **GPS Jump:** przesunięcie pojedynczego punktu o 3 km (symulacja usterki).
3. **Heavy Noise:** dodanie ok. 150-metrowego szumu Gaussa do każdego punktu trasy.
4. **Reversal:** odwrócenie chronologii trasy.

Dzięki temu uzyskaliśmy własny zbiór testowy z pewnymi etykietami. Następnie wyliczyliśmy metryki ROC-AUC oraz PR-AUC, aby sprawdzić, czy Isolation Forest potrafi poprawnie wychwycić te sztuczne błędy na podstawie wygenerowanych przez nas reprezentacji. Dodatkowo przeprowadziliśmy analizę jakościową, wyświetlając na mapie prawdziwe trasy, które modele uznały za najbardziej podejrzane.

5. Wyniki i analiza

Wyniki eksperymentów ukazały wyraźne różnice w tym, jak oba modele definiują anomalie:

1. Anomalie geometryczne i punktowe: Model Baseline okazał się znacznie skuteczniejszy w wykrywaniu objazdów (ROC-AUC: 0.82 vs 0.35 dla TS2Vec) oraz skoków GPS (0.97 vs 0.77). Wynika to z faktu, że tradycyjne statystyki, takie jak prędkość maksymalna, drastycznie reagują na takie błędy fizyczne, podczas gdy w głębokiej sieci informacja ta ulega rozmyciu.
2. Anomalie rozproszone i strukturalne: TS2Vec zdominował wykrywanie szumu (ROC-AUC: 0.99 vs 0.93). Sieć neuronowa analizuje płynność całej sekwencji i z łatwością zauważa nienaturalne, poszarpane struktury, podczas gdy Baseline ignoruje błędy, które nie generują potężnych skoków prędkości.
3. Problem z chronologią: Oba modele całkowicie poległy w teście odwrócenia czasu (Reversal), osiągając wynik zbliżony do losowego zgadywania (ok. 0.50). W przypadku Baseline'u jest to oczywiste – średnia prędkość czy długość są takie same

w obie strony. Z kolei dla TS2Vec ujawniło to ograniczenie naszej architektury: zastosowanie operacji mean pooling na samym końcu sieci spowodowało całkowitą utratę informacji o kolejności zdarzeń w czasie.

Warto zauważyć, że uzyskane przez nas wyniki PR-AUC były bardzo niskie (od 0.00 do 0.15). Nie wynika to z wadliwości modeli, lecz z naturalnego zjawiska w zbiorach bez etykiet. Zbiór z Porto był pełen prawdziwych, oryginalnych anomalii drogowych. Gdy nasz algorytm słusznie umieszczał je na szczycie rankingu jako "podejrzane", metryka obniżała nasz wynik precyzji, ponieważ trasy te nie należały do wąskiego grona 800 ręcznie wstrzykniętych przez nas błędów.

6. Wnioski i plany na przyszłość

Projekt jednoznacznie udowodnił, że nie istnieje uniwersalna metoda oceny anomalii – podejścia opisywane klasycznymi cechami i reprezentacjami samonadzorowanymi wyłapują fundamentalnie inne typy zdarzeń. Prosta statystyka sprawdza się idealnie do wyłapywania ekstremalnych wartości (długie kursy międzymiastowe, usterki sprzętu). Z kolei modele reprezentacji uczą się ukrytych zachowań geometrycznych i potrafią wskazywać rzadkie kształty ruchu na mapie miejskiej (kluczenie, pętle), nawet jeśli ich długość mieści się w normie.

Jako perspektywy rozwoju naszego rozwiązania proponujemy przede wszystkim zmianę mechanizmu agregacji w TS2Vec z *mean-poolingu* na mechanizmy uwagi, co pozwoliłoby zapobiec utracie informacji o kierunku czasu. Wartościowe byłoby również wzbogacenie danych wejściowych o kontekst czasowy (pora dnia, dzień tygodnia), co pozwoliłoby systemowi na lepsze odróżnianie normalnych zatorów drogowych od rzeczywistych anomalii w ruchu.